

Лабораторная работа

Анализ текстовых данных и TF-IDF (C++ и STL)

Теоретическая часть

1. Введение

При анализе текстовых данных важно уметь оценивать значимость слов в документах. Одним из базовых подходов является модель **TF-IDF** (**T**erm **F**requency – **I**nverse **D**ocument **F**requency).

Она позволяет определить, насколько слово важно:

- в рамках конкретного документа
- относительно всей коллекции документов

2. TF (Term Frequency)

TF показывает, как часто слово встречается в документе.

$$TF(w, d) = \frac{count(w, d)}{|d|}$$

где:

- $count(w, d)$ — количество вхождений слова w в документ d
- $|d|$ — общее количество слов в документе

Интерпретация: чем чаще слово встречается в документе, тем выше его значимость.

3. IDF (Inverse Document Frequency)

IDF показывает, насколько слово является редким во всей коллекции документов.

$$IDF(w) = \log \left(\frac{N}{df(w)} \right)$$

где:

- N — общее количество документов
- $df(w)$ — количество документов, содержащих слово w

Интерпретация:

- часто встречающиеся слова имеют низкий IDF
- редкие слова имеют высокий IDF

4. TF-IDF

$$TF\text{-}IDF(w, d) = TF(w, d) \times IDF(w)$$

Интерпретация: высокое значение TF-IDF получают слова, которые часто встречаются в документе, но редко — в других документах.

Постановка задачи

Дан набор текстовых документов, хранящихся в отдельных файлах.

Необходимо реализовать программу, которая:

1. Загружает документы из файлов
2. Обработывает текст
3. Вычисляет TF, IDF и TF-IDF
4. Отвечает на запросы пользователя

Входные данные

Список документов

Имена файлов с документами задаются во внешнем текстовом файле `documents.txt`.

Формат файла:

- каждая строка содержит имя одного документа
- каждая строка соответствует отдельному файлу

Пример содержимого файла:

```
doc1.txt
doc2.txt
doc3.txt
```

Программа должна:

- считать имена файлов из `documents.txt`
- загрузить соответствующие документы для последующей обработки

Документы

Каждый документ хранится в отдельном текстовом файле.

Запросы

```
<query type> <arguments>
```

Типы запросов

1. Статистика по слову

Формат:

```
WORD <word>
```

Пример:

```
WORD learning
```

Вывод:

```
Word: learning
Documents total: 5
Documents with word: 3
IDF: 0.5108
Appears in:
- doc1.txt
- doc3.txt
- doc5.txt
```

2. Статистика слова в документе

Формат:

```
WORD_IN_DOC <word> <document>
```

Пример:

```
WORD_IN_DOC learning doc1.txt
```

Вывод:

```
Word: learning
Document: doc1.txt
Count: 4
TF: 0.1333
TF-IDF: 0.0681
```

3. Статистика по документу

Формат:

```
DOC <document>
```

Пример:

```
DOC doc1.txt
```

Вывод:

```
Document: doc1.txt
Total words: 120
Unique words: 45
```

```
Top words:
1. learning (0.0912)
2. machine (0.0850)
3. data (0.0721)
4. model (0.0610)
5. algorithm (0.0553)
```

4. Поиск документа

Формат:

```
QUERY <wodr 1> <word 2> ...
```

Пример:

```
QUERY machine learning
```

Вывод:

```
Query: machine learning
Results:
1. doc3.txt (0.1823)
2. doc1.txt (0.1501)
3. doc2.txt (0.0420)
```

Требования к реализации

Обязательно использовать:

- контейнеры STL:
 - vector
 - unordered_map
 - set
- алгоритмы STL:
 - sort
 - transform
- лямбда-функции

Требования к программе

- загрузка данных из файлов
- приведение текста к нижнему регистру
- удаление знаков препинания
- разбиение кода на функции
- обработка некорректных запросов

Результат работы

Программа должна:

- загружать документы
- вычислять TF, IDF, TF-IDF
- обрабатывать запросы
- выводить результаты в заданном формате